Informe de revisión de lecturas THM 30-35 µg/L y efecto sobre el soft-sensor de Huesna

1. Contexto

Durante la revisión del soft-sensor de THM asociado al sensor DEPÓSITO ETAP MULTIPARAMÉTRICA, planta indicó la posible existencia de un problema en determinadas lecturas de THM próximas al rango 30-35 µg/L.

La auditoría histórica realizada sobre los datos disponibles mostró que este rango aparece con bastante frecuencia en el histórico, representando aproximadamente un 15,8 % de las mediciones de THM. Además, se observan numerosos períodos sostenidos dentro de dicho rango, especialmente durante junio, julio y agosto de 2026.

Tras contrastar esta información con planta, se indicó que el período potencialmente afectado debía considerarse aproximadamente desde el 12 de junio hasta el 14 de agosto de 2026. En particular, desde planta se confirmó la existencia de una medida de 31,47 µg/L el 14 de agosto, por lo que para el experimento se utilizó de forma conservadora el intervalo completo: 12/06/2026 00:00 - 14/08/2026 23:59.

2. Experimento realizado

Para comprobar si estas lecturas estaban perjudicando el comportamiento del soft-sensor, se realizó una nueva ejecución experimental partiendo de la configuración utilizada en la validación formal de septiembre. La única modificación introducida fue la siguiente:

Durante el período comprendido entre el 12/06/2026 y el 14/08/2026 se eliminaron como valores objetivo de entrenamiento todas las medidas de THM comprendidas entre 30 y 35 µg/L, ambos incluidos.

Las variables multiparamétricas correspondientes a esos mismos instantes (pH, UVAS, conductividad, turbidez, cloro y temperatura) no fueron eliminadas, ya que no existe evidencia de que dichas señales fueran incorrectas. Únicamente se invalidó la medida de THM utilizada como referencia supervisada.

Para garantizar una comparación directa con la validación formal anterior, se utilizaron exactamente los mismos datos disponibles hasta el 21/09/2026 13:35, la misma semana de validación y el mismo período de test final.

3. Efecto sobre el conjunto de entrenamiento

La exclusión del rango 30-35 µg/L tuvo un efecto considerable sobre el volumen y la distribución de los datos utilizados para entrenar el modelo. El número de muestras de entrenamiento pasó de:

- 228.931 muestras en el modelo de referencia.
- 189.225 muestras tras aplicar el nuevo filtro.

Esto supone eliminar aproximadamente 39.700 ejemplos de entrenamiento. Además, la distribución de THM utilizada durante el aprendizaje cambió de manera significativa:

Distribución THM entrenamiento	Modelo original	Experimento 30-35
Media	20,85	18,30
Mediana	18,60	12,60
Percentil 75	33,60	27,00

Por tanto, la eliminación global de este rango modifica de forma importante el régimen de THM que observa el modelo durante su entrenamiento.

4. Resultados

La comparación sobre el mismo período de test, comprendido entre el 14 y el 21 de septiembre, es la siguiente:

Métrica	Modelo de referencia	Eliminando 30-35 µg/L
MAE	1,996 µg/L	2,239 µg/L
RMSE	2,393 µg/L	2,581 µg/L
Bias	+1,832 µg/L	+2,117 µg/L
SMAPE	11,25 %	12,50 %

La eliminación de todas las lecturas del rango 30-35 µg/L provoca aproximadamente:

- +12,2 % de MAE.
- +7,9 % de RMSE.
- +15,6 % de sesgo medio.

Es decir, el modelo entrenado sin estas muestras presenta un comportamiento ligeramente peor sobre datos futuros completamente reservados.

También se comprobó específicamente el cambio de régimen observado alrededor del 17 de septiembre. La exclusión del rango 30-35 no elimina ese comportamiento: únicamente produce una mejora mínima el día 17, mientras que las predicciones empeoran ligeramente durante la mayoría de los restantes días del test.

5. Interpretación

Estos resultados sugieren que no resulta adecuado considerar automáticamente incorrectas todas las medidas de THM comprendidas entre 30 y 35 µg/L durante junio-agosto.

Una parte importante de dichas medidas parece contener información útil y coherente con el comportamiento real del proceso. Eliminarlas en bloque reduce considerablemente el conjunto de entrenamiento y altera su distribución, haciendo que el modelo generalice peor hacia datos posteriores.

Esto no implica que no haya existido una incidencia en el sensor de THM. El resultado indica únicamente que el problema probablemente afecta a determinados períodos o comportamientos concretos, y no necesariamente a todas las lecturas cuyo valor se encuentre entre 30 y 35 µg/L. Por este motivo, se mantiene como referencia el modelo validado formalmente en septiembre, sin aplicar esta exclusión global.

6. Información necesaria por parte de planta/proveedor

Para poder tratar correctamente esta incidencia sería necesario conocer con mayor precisión qué identificó el proveedor como anómalo. En particular, sería útil confirmar:

- Las fechas y horas concretas afectadas.
- Si el problema consistía en un valor bloqueado o prácticamente constante, un offset de medida, un problema de calibración u otro tipo de fallo.
- Si todas las medidas entre 30-35 µg/L durante ese período deben considerarse erróneas o únicamente determinados episodios.
- Si existe alguna referencia externa o comprobación de laboratorio que permita identificar cuáles de esas medidas son incorrectas.

Una vez disponible esta información, se podrá repetir el experimento excluyendo únicamente las observaciones realmente afectadas y evaluar de nuevo su impacto sobre el soft-sensor.